

Cahier des Charges & Cadrage



Année Universitaire 2025-2026

DOCUMENT TECHNIQUE

Cahier des Charges & Cadrage

Système automatisé de collecte, d'enrichissement et de scoring par IA de données événementielles
B2B

Version : 1.0 | Date : Avril 2026

Tuteur entreprise: Eden Suire

Tuteur académique : Carl Vincent

Stagiaire : Anas Kiouaz

I Contexte & Enjeux	2
I.1 Présentation du besoin	2
I.2 Objectifs principaux du stage	3
I.3 Cibles et utilisateurs finaux	3
II Périmètre et Spécifications Fonctionnelles	3
II.1 Module d'acquisition de données (Extraction Web / Scraping)	3
II.2 Module d'enrichissement de données	3
II.3 Module d'Intelligence Artificielle	3
II.3.a Grille de scoring (échelle 0-10)	3
II.3.b Structure du prompt	4
II.3.c Schéma JSON de sortie	4
II.3.d Choix du modèle	4
II.3.e Contrainte anti-surcharge cognitive	5
II.4 Interopérabilité et Intégration CRM	5
II.5 Module de restitution et d'interaction (Interface utilisateur)	5
III Spécifications Techniques et Architecture	5
III.1 Architecture logicielle envisagée	5
III.2 Stack technique	5
III.3 Intégration et flux de données HubSpot	5
III.4 Sécurité et RGPD	6
III.4.a Sécurité applicative :	6
III.4.b Conformité RGPD :	6
IV Stratégie de Test et Qualité Logicielle	6
IV.1 Méthodologie de Test et Critères d'Acceptation	6
IV.2 Tests fonctionnels et de performance	6
IV.3 Processus d'amélioration continue	7
V Évolutions Possibles (Phase 2)	7
VI Planning et Livrables	7
VI.1 Liste des livrables	7

I Contexte & Enjeux

I.1 Présentation du besoin

Wirepas est une entreprise technologique spécialisée dans les protocoles de communication sans fil mesh pour l'IoT industriel. Son activité commerciale repose en partie sur la participation à des salons professionnels internationaux (Electronica, Smart City Expo, IBS Event, Enlit Europe, etc.) pour identifier et convertir des prospects B2B (12 salons par an). Le processus actuel de traitement des listes d'exposants est presque entièrement manuel, ce qui représente environ 3 jours de travail commercial non productif par salon :

Étape	Situation Actuelle	Impact (Temps)
Collecte	consultation web	8-9h
Analyse	Microsoft Copilot, Manuelle	8-9h
Saisie CRM	Copier-coller dans HubSpot	5-6h

I.2 Objectifs principaux du stage

Le projet consiste à concevoir et développer une application interne permettant de :

- Réduire le temps global de préparation d'un salon de 3 jours-homme (≈ 22 heures) à moins de 45 minutes pour 1 000 exposants, dont au maximum 10 minutes de supervision humaine active. Le reste du traitement s'exécute en arrière-plan, libérant le commercial pour des tâches à plus forte valeur ajoutée. .
- Automatiser la collecte d'informations (Entreprise, Contact, Stand) depuis les sites des salons.
- Enrichir les données collectées (nom de domaine, secteur d'activité...)
- Sélectionner et qualifier les sociétés les plus pertinentes via un scoring basé sur les critères de l'équipe commerciale.
- Étiqueter les doublons et les entreprises non pertinentes avant toute création dans le CRM.
- Créer automatiquement les sociétés contacts et tâches dans HubSpot avec une nomenclature standardisée (ex pour les taches : `<NomSalon><Année>_[NEW]_<NomSociété>` ou `<NomSalon><Année>_<NomSociété>`).

I.3 Cibles et utilisateurs finaux

L'équipe Commerciale Wirepas : Utilisateurs principaux du service pour préparer leur salons.

Le Product Owner (Eden. S.) : Validation des critères de scoring et des fonctionnalités.

Référent technique HubSpot (Riikka Palola) : Supervision de l'intégration des données dans le CRM.

II Périmètre et Spécifications Fonctionnelles

II.1 Module d'acquisition de données (Extraction Web / Scraping)

L'extracteur récupère la liste complète des exposants d'un salon à partir d'une URL et d'un exemple témoin (nom/stand) fournis par l'utilisateur. Par analyse du nœud DOM, le script identifie le contenu cible et extrait les éléments frères.

- Format de sortie : JSON (ex: `[{"company": "Electronica", "booth": "C6.151"}]`).
- **Exigences techniques** : Capacité nominale de **1 000 entrées par exécution** (couvre 95 % des salons cibles), capacité maximale de **5 000 entrées** (cas Electronica), mécanisme de retry exponentiel ($2s \rightarrow 4s \rightarrow 8s$) et feedback d'avancement en temps réel.

II.2 Module d'enrichissement de données

Ce module nettoie et standardise le nom de l'entreprise pour retrouver son nom de domaine, son secteur et les technologies utilisées (via API externes type Clearbit). Activité de l'entreprise : Récupération du code APE/NAF (INSEE). Les préfixes cibles sont : 26 (Hardware/Électronique), 46.5 (Commerce de gros B2B IT/Telecom), 61 (Télécommunications), 62 (Logiciel/IT), 71 (Ingénierie). Sortie : Schéma JSON complet incluant le nom de domaine et si possible de secteur d'activité.

II.3 Module d'Intelligence Artificielle

Ce module assure la classification et l'évaluation automatisées des prospects en s'appuyant sur un Large Language Model (LLM) piloté par un prompt structuré et un contexte métier dédié à Wirepas (technologies mesh, marchés cibles, profil ICP).

II.3.a Grille de scoring (échelle 0-10)

Le score final est une moyenne pondérée de quatre axes, validés avec le Product Owner :

Axe	Pondération	Critères évalués
Pertinence technologique	40 %	Présence de mots-clés IoT, mesh, LPWAN, industrial wireless, smart metering, asset tracking
Adéquation sectorielle	30 %	Code APE/NAF cible (26, 46.5, 61, 62, 71) ou secteur déclaré (industrie, énergie, smart city, logistique)
Maturité commerciale	20 %	Taille d'entreprise estimée, présence internationale, indices de scaling (levées de fonds, recrutements)
Signal salon	10 %	Type de stand, position sur le salon, co-exposition avec partenaires connus

Seuils de qualification :

- **0-3** : Non pertinent — étiqueté [REJECTED], non remonté dans HubSpot
- **4-6** : À surveiller — créé dans HubSpot avec tâche basse priorité
- **7-10** : Prospect chaud — créé dans HubSpot avec tâche haute priorité et notification commerciale

II.3.b Structure du prompt

Le prompt suit une architecture en trois couches pour limiter les hallucinations (cf. risque TECH-01) :

1. **System prompt** figé : rôle, contexte Wirepas, contraintes de sortie JSON strict
2. **Few-shot examples** : 5 exemples annotés manuellement par le PO (2 prospects pertinents, 2 non pertinents, 1 ambigu)
3. **User prompt** dynamique : données enrichies de l'entreprise à scorer

II.3.c Schéma JSON de sortie

```
{
  "company_name": "string",
  "domain": "string",
  "score": 0-10,
  "score_breakdown": {
    "tech_relevance": 0-10,
    "sector_fit": 0-10,
    "commercial_maturity": 0-10,
    "trade_show_signal": 0-10
  },
  "verdict": "REJECTED | WATCH | HOT",
  "summary": "string (max 280 caractères)",
  "keywords": ["string", "..."],
  "reasoning": "string (max 500 caractères)"
}
```

II.3.d Choix du modèle

Un benchmark sera réalisé en début de phase L5 sur 50 prospects annotés, comparant trois candidats sur les axes coût/qualité/latence. Le modèle retenu sera **figé sur une version explicite** (pas de tag latest, cf. risque AI-03). Le routage est assuré via OpenRouter pour permettre un basculement rapide en cas de défaillance.

II.3.e Contrainte anti-surcharge cognitive

Conformément au risque UX-02, le champ summary est strictement limité à 280 caractères dans le prompt système, garantissant une lecture commerciale en moins de 15 secondes.

II.4 Interopérabilité et Intégration CRM

Le module crm vérifie l'existence des entreprises dans HubSpot (via SDK/API, remplaçant la solution initiale Zapier) afin d'enregistrer l'ID d'entreprise pour par la suite pouvoir la lier à la tâche et lui appliquer la bonne nomenclature. De plus, l'application assure l'automatisation du flux de données vers le CRM en procédant à la création de la Société (Company) ainsi que de la Tâche pour les nouvelles sociétés. Dans une perspective d'évolution technique (Phase 2), le système prévoit également l'intégration automatisée des Contacts,

II.5 Module de restitution et d'interaction (Interface utilisateur)

L'interface consiste en une application fonctionnelle simplifiée centralisant la saisie des données sources via un formulaire d'entrée, le déclenchement manuel du module d'analyse et la restitution des indicateurs clés. Elle permet de piloter l'exécution du service et de visualiser immédiatement les résultats essentiels, tels que le taux de présence des prospects dans HubSpot et la distribution des scores de pertinence obtenus.

III Spécifications Techniques et Architecture

III.1 Architecture logicielle envisagée

Le système sera découpé en pipelines de traitement de données (scraping -> enrichissement -> IA -> CRM) connectés à un dashboard, L'intégration potentielle au **Wirepas Developer Portal** est envisagée.

III.2 Stack technique

- **Scraping** : Scrapling, Crawl4AI, Playwright.
- **Enrichissement** : Clearbit, API (ex : recherche-entreprises.api.gouv.fr/search).
- **IA** : Routage via OpenRouter (permet de basculer entre modèles sans changer le code). Les modèles candidats pour le benchmark de qualification sont Claude Sonnet 4.5, Kimi K2 et GPT-4o-mini. Le modèle retenu sera figé sur une version explicite (ex : claude-sonnet-4-5) afin de prévenir la dérive (cf. AI-03). Outil de développement : OpenCode (CLI agentique pour l'itération sur les prompts).
- **Interface Front** : Streamlit (prototypage rapide, natif Python) puis évolution vers React/Vue.
- **Base de données temporaire** : CSV ou SQLite.
- **CRM** : HubSpot API.

Cette liste de technologies est non exhaustive et susceptible d'ajustements durant le développement.

III.3 Intégration et flux de données HubSpot

Objets créés :

- **Société (Company)** : Création de la fiche entreprise avec les informations extraites (nom, domaine, description).
- **Contact (contact)** : Ajout des décideurs identifiés lors de la phase d'enrichissement.
- **Tâche (Task)** : Génération d'une activité de prospection assignée aux commerciaux, contenant le compte-rendu de l'analyse IA.

Logique d'association : Le script assure automatiquement le lien hiérarchique entre le contact et sa société, ainsi que l'affectation de la tâche à l'entreprise correspondante.

III.4 Sécurité et RGPD

III.4.a Sécurité applicative :

Gestion des secrets : variables d'environnement via fichier `.env` (jamais commité), chargées au démarrage. Rotation trimestrielle des clés API. Scan automatique du dépôt avec `gitleaks` en pre-commit hook (cf. SEC-01). **Communications** : HTTPS obligatoire pour tous les appels sortants, vérification des certificats TLS activée. **Restriction CORS** : whitelist explicite des origines autorisées côté API interne. **Prévention XSS** : échappement systématique des données scrapées avant affichage (Streamlit le gère nativement, à valider lors de la migration React). **Rate limiting** : 100 requêtes/minute côté HubSpot (limite officielle), 60 requêtes/minute côté OpenRouter, mécanisme de back-off exponentiel en cas de 429. **Logs et auditabilité** : journalisation horodatée de chaque exécution (utilisateur, salon, volumétrie, durée, erreurs) en base SQLite locale, conservée 12 mois. **Validation des entrées** : sanitisation des URL fournies par l'utilisateur (whitelist de schémas `https://` uniquement), prévention des injections de prompt côté LLM (cf. TECH-03).

III.4.b Conformité RGPD :

Base légale : Intérêt légitime (RGPD Art. 6.1.f) pour la prospection B2B, conformément aux lignes directrices CNIL sur la prospection commerciale (mise à jour 2024). Périmètre Phase 1 : seules les données relatives aux personnes morales sont **Périmètre** : Scraping autorisé uniquement sur les données publiques des sites officiels des salons. Respect strict du `robots.txt`. L'utilisateur final est seul responsable du respect des CGU des sites sources.

IV Stratégie de Test et Qualité Logicielle

IV.1 Méthodologie de Test et Critères d'Acceptation

Tests Unitaires et Couverture de Code (Code Coverage) Mise en place de tests automatisés pour valider la logique d'extraction, les fonctions de nettoyage et d'enrichissement de données et les appels API. Exigence de qualité : Couverture de code (Code Coverage) minimale fixée à $\geq 80\%$, justifiée par la génération de rapports de couverture (Coverage HTML).

Tests Front-end et End-to-End (E2E) Utilisation de **Cypress** pour automatiser les tests d'intégration et simuler le parcours de l'utilisateur final sur l'interface UI (validation des filtres, affichage conditionnel, déclenchement de l'export vers HubSpot).

Tests Utilisateurs et Ergonomie (UX) Passation de tests selon le protocole **Think Aloud** (pensée à voix haute) avec l'équipe commerciale Wirepas. L'objectif est d'identifier les frictions lors de l'utilisation du dashboard et de valider les choix d'interface.

IV.2 Tests fonctionnels et de performance

- T1/T2 : Extraction réussie à $\geq 95\%$ sur Electronica et IBS Event en moins de 5 minutes pour 1 000 exposants, et moins de 20 minutes pour 5 000 exposants.
- T3 : Score IA cohérent validé manuellement sur 50 prospects.
- T4 / T5 : 0 doublon créé dans HubSpot ; format de nomenclature respecté à 100%.
- T6 : Filtrage fonctionnel (uniquement IoT/Industrie).
- T7 : Chargement du Dashboard en < 3 secondes pour 1 000 prospects affichés.
- KPIs visés :

- Temps de traitement complet d'un salon de **1 000 prospects < 45 minutes** (extraction + enrichissement + scoring + push CRM)
- Précision IA $\geq 85\%$ sur l'échantillon de validation
- Satisfaction UX $\geq 4\%$
- **KPIs d'impact métier :**
- Taux d'adoption par l'équipe commerciale $\geq 80\%$ des salons traités via l'outil
- Taux de conversion lead scoré $\geq 7 \rightarrow$ RDV qualifié $\geq 15\%$ (baseline actuelle à mesurer en début de stage)
- Nombre moyen de prospects qualifiés par salon ≥ 30 (vs. estimation actuelle à confirmer avec le PO)
- Réduction du temps commercial non productif : objectif $\geq 90\%$ vs. processus manuel actuel

IV.3 Processus d'amélioration continue

Suivi encadré par des points de synchronisation réguliers :

- **Hebdomadaire** : Avec le PO (E. S.) pour le déblocage technique et avec le Tuteur académique (V. Carl) pour le rapport.
- **Fin de phase** : Validation des jalons avec le tuteur entreprise et académique.

V Évolutions Possibles (Phase 2)

Identification avancée : Le scraping et la génération d'informations spécifiques sur les contacts (décideurs) seront traités dans un second temps.

Collecte automatisée (scraping) des données de contact

rajouter le un lien entre le dernier deal fait avec la societer et la taches affin que le commercial est un point d'entrer pour prendre contact

Migration Front-end : Passage de Streamlit à une stack React/Vue complète si le temps le permet.

VI Planning et Livrables

VI.1 Liste des livrables

TE : tuteur entreprise **TA** : tuteur académique

	Livrable	Format	Destinataire	Date cible
L1	Fiche de liaison	PDF	TE/TA, Secrétariat IUT	24/04/2026
L2	Cadrage, veille, Cahier des charges	PDF, POCs,	TE/TA, Equipe dev	24/04/2026
L3	Module scraping	Rapport, Extract .json	TE/TA	30/04/2026
L4	Module d'enrichissement	Rapport, Démo,	TE/TA	08/05/2026
L4b	Rencontre avec l'équipe commerciale	Rapport	Équipe Commerciale	semaine du 08/05/2026
L5	Module Scoring	Rapport,	TE/TA	18/05/2026
L6	Configuration API CRM	Rapport, MVP	TE/TA	22/05/2026

L6b	Présentation commerciale	Réunion / Démo	Équipe Commerciale	semaine du 23/05/2026
L7	UI/UX (Critères ergo)	GitHub, Rapport	Tuteurs	29/05/2026
L8	Documentation technique	Confluence, Markdown, GitHub	TE/TA + Secrétariat IUT	05/06/2026
L9	Version préliminaire rapport	PDF	Tuteurs	06/06/2026
L10	Tests, corrections	% Coverage	TE/TA	12/06/2026
L11	Rapport de stage final	PDF	Tuteurs	13/06/2026
L12	Soutenance de stage	Soutenance	TE/TA + Jury IUT	23/06/2026

Voici le tableau unique fusionnant les deux listes de risques, en ajoutant la colonne « Catégorie » pour les risques du premier tableau afin d'harmoniser la structure.

ID Risque	Catégorie	Description du Risque	Probabilité	Impact	Stratégie d'Atténuation
JUR-01	Juridique	Sanction CNIL / RGPD pour scraping illégal	Élevée	Critique	Audit et respect strict du robots.txt ainsi que des CGU
TECH-01	Technique	Hallucinations de l'IA dans le scoring	Moyenne	Moyenne	Framework d'évaluation HatchWorks en 4 couches
TECH-02	Technique	Dérive du DOM et rupture des scrapers	Élevée	Moyenne	Utilisation de sélecteurs stables et auto-healing 4
TECH-03	Technique	Injection de prompts (Prompt Injection)	Faible	Élevée	Filtrage des entrées et isolation des agents
OP-01	Opérationnel	Écrasement de données CRM par synchro défectueuse	Élevée	Élevée	Définition stricte de la source de vérité
OP-02	Opérationnel	Biais algorithmique et discrimination des leads	Moyenne	Moyenne	Audit régulier des modèles et diversité des données
FIN-01	Financier	Explosion des coûts d'API (Scaling non maîtrisé)	Moyenne	Élevée	Monitoring en temps réel et routage sémantique

FIN-02	Financier	Échec de l'adoption par les équipes sales	Élevée	Critique	Formation continue et UX centrée sur l'humain
ENV-01	Environnemental	Impact carbone et non-conformité ESG	Faible	Faible	Utilisation d'IA frugale et monitoring ADEME
TECH-04	Technique	Blocage IP (Anti-botting)	Élevée	Moyenne	Proxies tournants + délais aléatoires.
DATA-01	Données	Données périmées (Obsolescence)	Moyenne	Faible	Champ « Date d'extraction » sur HubSpot.
SEC-01	Sécurité	Fuite de clés API (GitHub)	Faible	Critique	Fichiers .env + gestionnaire de secrets.
TECH-05	Technique	Timeouts / Crash (Gros volumes) : L'extraction de 5 000 entrées dépasse le temps de réponse maximal autorisé	Moyenne	Moyenne	Batch processing + files d'attente.
AI-03	IA	Dérive du modèle (Mise à jour)	Moyenne	Moyenne	Figurer la version (pas de tag « latest »).
INT-01	Intégration	Changement de schéma HubSpot	Faible	Élevée	Health check API au démarrage.
UX-02	Humain	Surcharge d'information : Le résumé IA est trop long ou complexe, décourageant le commercial de le lire.	Élevée	moyenne	Contrainte stricte de mots dans le prompt.
TECH-06	Technique	Failles bibliothèques (Legacy)	Faible	Moyenne	Audits (npm audit) + MAJ régulières.